

Universidad Pontificia Comillas
ICAI

PROYECTO FINAL

Economía y Empresa

María González Gómez y Lydia Ruiz Martínez

PREDICCIÓN DE LA TASA DE INFLACIÓN



Curso 2025-2026

Resumen

Este informe presenta el diseño y la evaluación de una plataforma reproducible para predecir la inflación en España a partir de series históricas del Instituto Nacional de Estadística (INE). Para ello, se implementa un *pipeline end-to-end* cuyo objetivo es la automatización de todo el proceso: desde la descarga, depuración y enriquecimiento de los datos, hasta el entrenamiento de modelos, generación de predicciones con intervalos de confianza y la creación tanto de salidas visuales como de un informe técnico.

El sistema implementado integra distintos enfoques de modelado. Se emplea un modelo ARIMA clásico, frente al cual se comparan alternativas más avanzadas como Random Forest y redes neuronales LSTM (Long Short-Term Memory). Tras la evaluación cuantitativa en el periodo de prueba, el mejor rendimiento se alcanza con Random Forest, que obtiene un MAE (Mean Absolute Error – Error Absoluto Medio) aproximado de 0,97, un RMSE (Root Mean Square Error – Error cuadrático medio de la raíz) de 1,95 y un MAPE (Mean Absolute Percentage Error – Error porcentual absoluto medio) en torno al 17,5 %. En términos prácticos, las previsiones medias se sitúan alrededor del 2,8 % para el horizonte mensual considerado, con bandas de incertidumbre de unos 0,6 puntos porcentuales.

Índice

Índice	2
1. Introducción	3
2. Contenidos del repositorio y cómo usarlo	3
2.1. Ejecución mínima	4
2.2. Configuración esencial	4
3. Fuentes de datos y trazabilidad	5
3.1. Trazabilidad y auditoría	5
4. Qué se estudia, metodología y resultados con gráficos	6
4.1. Objeto de estudio y preguntas	6
4.2. Metodología	6
4.3. Resultados empíricos e interpretación	7
5. Limitaciones conocidas y mejoras futuras	10
6. Conclusión	12

1. Introducción

La inflación es un fenómeno macroeconómico que incide directamente en el poder adquisitivo de los hogares, la competitividad de las empresas, la sostenibilidad de las finanzas públicas y la orientación de la política monetaria. La capacidad de anticipar su trayectoria, incluso a horizontes cortos (3–12 meses), tiene valor operativo para equipos de análisis económico, planificación presupuestaria y gestión de riesgo.

En este trabajo abordamos la predicción de la tasa de inflación en España a partir de series oficiales del INE. Los campos que este trabajo busca cubrir son:

1. **Rigor en el dato:** trazabilidad completa desde la fuente (INE, servicio WS-Tempus) y controles de calidad.
2. **Disciplina de modelización:** una línea base *time-series* ARIMA y alternativas no lineales como Random Forest y LSTM para capturar patrones potencialmente no lineales y dependencias complejas.
3. **Lectura económica:** interpretar resultados en clave macro (tendencia, estacionalidad, shocks transitorios) evitando sobreajuste y teniendo presente la incertidumbre estimada.

El proyecto pone un énfasis especial en garantizar que todo el flujo de trabajo sea reproducible, auditable y fácilmente utilizable por profesionales del ámbito económico, incluso aquellos con una mínima experiencia técnica. Para lograrlo, se ha diseñado una estructura de repositorio clara y bien documentada, acompañada de una configuración declarativa y una ejecución del pipeline sencilla e intuitiva. El resultado final se presenta de forma integral, con gráficos explicativos, tablas de métricas comparativas y un informe técnico en formato PDF que resume las conclusiones principales y facilita su interpretación.

2. Contenidos del repositorio y cómo usarlo

El repositorio se ha estructurado cuidadosamente para favorecer la reproducibilidad, claridad y separación de responsabilidades entre los distintos componentes del proyecto. A continuación se describen las principales carpetas y su función:

- **config/:** contiene el fichero de configuración `config.yaml`, donde se definen las fechas de extracción, las rutas de trabajo, el nivel de *logging* y, cuando aplica, los identificadores de las series del INE.
- **data/raw/ y data/processed/:** almacenan los datos en su forma original y tras el procesamiento, respectivamente. La fase de limpieza estandariza las fechas, maneja valores ausentes y atípicos, y genera características derivadas (*features*) como ventanas móviles.

- `models/`: guarda los artefactos de los modelos entrenados (`arima_model.pkl`, `random_forest_model.pkl`, `lstm_model.pkl`) junto con su manifiesto de entrenamiento.
- `reports/`: incluye las salidas generadas para el usuario, tales como archivos de predicciones (`predictions.csv/json`), visualizaciones en formato PNG, el estado de ejecución del *pipeline* (`pipeline_execution_state.json`) y el informe técnico en formato PDF.
- `src/`: agrupa los componentes principales del *pipeline*. Entre ellos se incluyen los módulos de:
 - extracción de datos (`ine_extractor.py`);
 - limpieza de datos (`data_cleaner.py`);
 - ingeniería de características (`feature_engineering.py`);
 - entrenamiento (`model_trainer.py`);
 - predicción (`predictor.py`);
 - generación de informes (`report_generator.py`).

El archivo `main.py` actúa como orquestador del flujo completo de ejecución.

2.1. Ejecución mínima

Con Python 3.10–3.12 y las dependencias instaladas desde `requirements.txt`, el sistema puede ejecutarse con un único comando:

```
python src/main.py
```

Este comando lanza de forma secuencial todas las etapas del proceso: descarga → limpieza → generación de *features* → entrenamiento → predicción → generación de reportes.

Los registros de la ejecución se almacenan automáticamente en `logs/inflation_prediction.log`.

2.2. Configuración esencial

La configuración principal se encuentra en el archivo `config/config.yaml`, donde se definen los siguientes parámetros:

- `data.start_date` y `data.end_date`: delimitan el rango temporal de análisis.
- Endpoints WSTempus del INE: especifican las fuentes para el IPC general, las desagregaciones por grupo y el índice armonizado (IPCA).
- `prediction.horizon.months`: establece el horizonte de predicción en meses (por defecto, 12).
- `paths` y `logging`: definen las rutas de trabajo y los parámetros de registro de ejecución.

3. Fuentes de datos y trazabilidad

El proyecto utiliza series oficiales del Instituto Nacional de Estadística (INE), obtenidas a través del servicio WSTempus. Estas fuentes garantizan la consistencia metodológica y la comparabilidad temporal de las observaciones empleadas. Las series clave incluidas en el análisis son:

1. **IPC general** (% interanual): actúa como variable objetivo del modelo de predicción.
2. **IPC por grupos** (alimentación, energía, transporte, etc.): se utilizan como características explicativas para capturar composiciones sectoriales y efectos de base.
3. **IPCA** (índice armonizado de precios de consumo): aporta comparabilidad a nivel europeo y, en algunos casos, información complementaria relevante.

Detalle de subseries utilizadas. Además del IPC general (variable objetivo) y del IPCA (referencia armonizada europea), en nuestro caso incorporamos como covariable el grupo del INE *03.1 Prendas de vestir (Índice)*. La inclusión de este grupo como covariable refuerza el ajuste estacional del perfil mensual y aporta señal sobre la inflación de bienes no energéticos, especialmente en meses de rebajas. Su contribución marginal es menor en episodios dominados por shocks energéticos, pero ayuda a estabilizar el timing de las previsiones dentro del año. Como mejora, proponemos ampliar el set de grupos (energía, alimentos) y trabajar con subyacente para separar mejor los motores de la inflación.

3.1. Trazabilidad y auditoría

El *pipeline* implementado mantiene un registro exhaustivo de la información necesaria para garantizar la reproducibilidad y trazabilidad de todo el proceso. Entre los elementos que se documentan se incluyen:

- fecha y hora de cada extracción
- URL e ID asociados a cada serie del INE
- número de observaciones descargadas y rango temporal cubierto
- versiones de las librerías empleadas y parámetros utilizados en la modelización
- métricas de evaluación y huellas digitales de los artefactos generados (*.pkl)

Toda esta información se almacena automáticamente en los archivos `pipeline.execution.state.json` y en los `logs` correspondientes.

Durante la fase de limpieza, el sistema también documenta las imputaciones realizadas y los recortes de datos atípicos cuando resultan necesarios.

El objetivo final es que cualquier tercero pueda replicar los resultados y auditar de forma transparente las decisiones tomadas en las etapas de transformación y modelado.

4. Qué se estudia, metodología y resultados con gráficos

4.1. Objeto de estudio y preguntas

El análisis realizado en este proyecto buscar responder a tres preguntas clave usando un horizonte mensual (hasta 12 meses):

1. ¿En qué rango se moverá la inflación interanual en España bajo condiciones actuales?
2. ¿Qué patrón de tendencia y estacionalidad presentan los datos históricos?
3. ¿Qué aproximación (lineal o no lineal) ofrece mejor compromiso entre sesgo, varianza y robustez?

4.2. Metodología

(1) Análisis exploratorio. Se estudia la trayectoria histórica y la distribución de la tasa interanual, junto con su descomposición clásica (tendencia, estacionalidad y residuo). Este paso permite identificar *shocks* transitorios (como los energéticos) frente a movimientos estructurales más persistentes en la inflación subyacente.




Figura 1: Evolución histórica, tendencia/volatilidad y distribución de predicciones

(2) Construcción de variables. Además del objetivo (IPC interanual), se generan:

- *lags* del objetivo y de grupos del IPC para capturar persistencia inflacionaria
- medias móviles y ventanas de volatilidad para suavizar el ruido y medir inestabilidad
- variables estacionales como el mes del año, efectos calendario) cuando procede
- transformaciones *winsorized* para limitar la influencia de valores extremos

(3) Modelos.

- **ARIMA (línea base).** Modelo clásico para series estacionarias tras diferenciación. Ofrece gran interpretabilidad y parsimonia, pero tiene poca flexibilidad ante no linealidades y rupturas estructurales.
- **Random Forest (RF).** Ensamble de árboles que capta interacciones entre grupos de precios y efectos no lineales. Es adecuado cuando los datos poseen una gran variedad de características y hay estacionalidades suaves o regímenes inflacionarios mixtos.
- **LSTM (opcional).** Red recurrente que puede modelar dependencias de largo plazo. Es muy útil cuando la dinámica de precios incorpora retardos amplios o persistencia extendida, pero requiere más datos y ajuste fino; además de que es sensible a la estandarización y al *early stopping*.

(4) **Evaluación.** Se emplean MAE, RMSE y MAPE sobre un *holdout* temporal. Se prioriza el error absoluto dada su facilidad de interpretación en puntos porcentuales y estabilidad. Se presentan también intervalos de confianza del 95 % como medida de incertidumbre predictiva para las trayectorias previstas, estos son además especialmente útiles para el análisis de riesgo macroeconómico.

4.3. Resultados empíricos e interpretación

Comparativa de modelos. La evaluación comparativa de los modelos revela que el algoritmo de *Random Forest* es el que presenta un mejor desempeño predictivo global, con un MAE de 0,999, un RMSE de 1,950 y un MAPE del 17,5 %. Le sigue en capacidad predictiva el modelo LSTM (RMSE $\approx$ 1,991), mientras que el modelo ARIMA clásico muestra un ajuste significativamente menor (MAE $\approx$ 2,496; RMSE $\approx$ 3,591; MAPE $\approx$ 61,4 %).

Desde una perspectiva económica, este orden de rendimiento no es casual. El período de muestra incluye fuertes perturbaciones no lineales, como el pico inflacionario de 2022-2023, impulsado por shocks de oferta en energía y cadenas globales de valor. Los modelos basados en árboles de decisión, como *Random Forest*, tienen la capacidad inherente de capturar relaciones no lineales y asimetrías en los datos sin imponer supuestos paramétricos restrictivos. En cambio, el modelo ARIMA, que se fundamenta en la linealidad y la estacionariedad, muestra sus limitaciones para

adaptarse a cambios bruscos de régimen o a la naturaleza de los shocks recientes. La superioridad de *Random Forest* sugiere, por tanto, que el proceso inflacionario reciente ha estado dominado por factores estructurales y de oferta con un comportamiento complejo, que los modelos de aprendizaje automático no paramétricos son más aptos para modelizar.




Figura 2: Comparación de rendimiento (MAE, RMSE, MAPE)

Descomposición y estacionalidad. La descomposición de la serie histórica de inflación permite aislar sus componentes fundamentales: tendencia, estacionalidad y residuo. Este análisis muestra una tendencia muy acusada durante 2022-2023, seguida de una fase de normalización que converge hacia un rango del 2-3,5 %. El componente estacional tiene una amplitud baja, lo que indica que los factores cíclicos intra-anales (como los precios de productos turísticos o energéticos en temporada) tienen una influencia limitada en la dinámica general.

Esta descomposición refuerza el hecho de que *Random Forest* es el modelo con mayor robustez para aprender de la tendencia y la estacionalidad, ya que puede incorporar de forma flexible variables externas y características estacionales sin requerir el supuesto de homocedasticidad estricta que subyace a los modelos ARIMA.




Figura 3: Descomposición de la serie: original, tendencia, estacionalidad y residuo

Trayectoria prevista e incertidumbre. Las proyecciones para el horizonte de previsión apuntan a una tasa de inflación media en torno al 2,8 %, con una mediana del 2,84 % y una desviación típica de aproximadamente 0,66 puntos porcentuales. El rango de predicciones se sitúa entre un mínimo del 1,38 % y un máximo del 3,64 %. Los intervalos de confianza del 95 % son notablemente estrechos (amplitud media de 0,6 p.p.), lo que indica un grado moderado de incertidumbre en las predicciones. Estos intervalos tienden a estrecharse en períodos donde la tendencia es más marcada y estable, mientras que se amplían ligeramente en los puntos de giro de la serie.

En términos macroeconómicos, estas distribuciones son coherentes con un escenario de normalización tras el shock inflacionario post-pandemia y la crisis energética. La convergencia hacia el rango meta del Banco Central Europeo (BCE) refleja los efectos base decrecientes y la transmisión gradual, aunque con retardos, de la política monetaria restrictiva implementada por el BCE, que ha contribuido a anclar las expectativas de inflación a medio plazo.




Figura 4: Histórico y predicciones con intervalo de confianza

Lectura macroeconómica sintética.

- **Tendencia y normalización:** La inflación española ha superado su fase más crítica y se encamina hacia una normalización en la banda del 2-3,5 %. Esto es consistente con la disipación progresiva de los shocks de oferta globales y la efectividad de la política monetaria.
- **Naturaleza de los riesgos:** El principal riesgo de que las cosas decaigan aun más, sería que la economía mundial se desacelere más rápido de lo esperado. Por otro lado, los factores que podrían hacer que la situación mejore menos o que la inflación se mantenga alta incluyen la volatilidad de los precios de la energía (como el petróleo y el gas) y de los alimentos básicos, así como posibles aumentos salariales que podrían hacer que la inflación subyacente se mantenga más tiempo de lo previsto.
- **Adecuación del marco de previsión:** Que los modelos no paramétricos funcionen mejor en este ciclo de inflación muestra lo útil que es combinar las herramientas económicas tradicionales con métodos de machine learning, sobre todo cuando la economía enfrenta cambios bruscos e inesperados, como los que hemos visto recientemente.

5. Limitaciones conocidas y mejoras futuras

Datos y cobertura. Aunque la serie del IPC es confiable, la capacidad de predecir la inflación mes a mes depende mucho de componentes muy volátiles, como




Figura 5: Evolución de la incertidumbre y bandas de confianza

la energía o los alimentos. Además, si solo usamos información del propio IPC, es difícil anticipar eventos externos que impacten la economía de manera repentina, como un aumento brusco del precio del petróleo o una crisis internacional.

Mejoras posibles: incorporar información adicional que se actualice con mayor frecuencia, como precios del crudo Brent, tipos de cambio, costos logísticos, indicadores de producción y consumo (PMIs) o expectativas de inflación, además de medidas de inflación subyacente que filtren los componentes más volátiles.

Especificación y estabilidad del modelo. Los modelos tradicionales como ARIMA son fáciles de interpretar y ofrecen una referencia base, pero son sensibles a cambios bruscos en el comportamiento de la economía. Modelos más avanzados, como Random Forest o LSTM, son más flexibles y capaces de capturar patrones complejos, pero son menos transparentes y, en el caso de LSTM, pueden “aprender de memoria” los datos si no se tiene suficiente información, lo que afecta su capacidad de generalización.

Mejoras posibles: aplicar técnicas de validación más robustas, como pruebas en ventanas móviles (*rolling origin*), validación cruzada para series temporales y combinar varios modelos mediante *ensembles* ponderados según su desempeño.

Incertidumbre y comunicación de resultados. Los intervalos o bandas que muestran los modelos reflejan la incertidumbre que el propio modelo puede estimar, pero no incluyen todos los riesgos posibles, especialmente eventos extremos como decisiones fiscales inesperadas o conflictos geopolíticos.

Mejoras posibles: calibrar los intervalos de forma empírica usando simulaciones (*bootstrap*), considerar escenarios alternativos (por ejemplo, uno optimista y otro pesimista) y realizar análisis de sensibilidad para entender cómo cambios en los supuestos afectan las predicciones.

Explicabilidad. Para que los resultados sean útiles económicamente, es importante entender cómo cada factor (o *feature*) contribuye a la predicción.

Mejoras posibles: usar herramientas como la importancia de las variables en Random Forest, SHAP para cuantificar el impacto de rezagos y estacionalidad en el IPC, y *partial dependence plots* para visualizar cómo cambian las predicciones cuando se modifica cada variable.

Operativa y reproducibilidad. Aunque el flujo de trabajo del modelo es reproducible, siempre se puede reforzar la gobernanza. Esto incluye fijar versiones exactas de los paquetes utilizados, registrar las semillas aleatorias y realizar pruebas automáticas para verificar que los resultados básicos sean consistentes.

Mejoras posibles: mantener un manifiesto del modelo, controlar versiones de los datos (*data versioning*) y registrar métricas clave de cada ejecución para asegurar trazabilidad y confianza en las predicciones.

6. Conclusión

En este proyecto se ha construido y documentado una solución end-to-end para la predicción de la inflación en España que cumple con los tres criterios exigidos en el enunciado docente: limpieza rigurosa del dato, construcción disciplinada del modelo y una interpretación económica clara de los resultados.

La aportación principal es un *pipeline* automatizado, trazable y reproducible que, a partir de series oficiales del INE, genera predicciones mensuales con intervalos de confianza, gráficos interpretables y un informe técnico listo para su consumo por equipos de economía.

Empíricamente, la alternativa no paramétrica *Random Forest* domina al ARIMA de referencia y a la especificación LSTM en el horizonte y *split* considerados, con errores medios razonables (MAE cercano a 1 pp; RMSE en el entorno de 2 pp) y bandas de incertidumbre de aproximadamente 0,6 puntos porcentuales. La senda proyectada sitúa la inflación en un rango compatible con la normalización posterior al ciclo de shocks 2022–2023, lo que sugiere una trayectoria central cercana al 2,8 % en el periodo evaluado, con riesgos inclinados hacia movimientos de materias primas y ciertos componentes volátiles del índice.

Desde una óptica económica, el mensaje clave es de prudente moderación: la descomposición muestra una estacionalidad acotada y una tendencia que converge,

pero la experiencia reciente recuerda que la inflación es sensible a shocks de oferta, cambios en costes energéticos y reajustes de expectativas. Por ello, además de proyectar una mediana plausible, el informe destaca la importancia de comunicar la incertidumbre y de complementar el modelo con señales adelantadas (energía, tipo de cambio, encuestas empresariales, subyacente).

Como líneas de trabajo futuras, proponemos:

1. Validación *rolling* y evaluación por ventana para asegurar estabilidad temporal.
2. *Ensembles* de Random Forest + LSTM ponderados por desempeño para reducir picos de error.
3. Explicabilidad mediante SHAP para reforzar la narrativa macroeconómica y la trazabilidad analítica.
4. Escenarios alternativos que cuantifiquen el impacto de shocks razonables.

Con todo ello, la plataforma proporciona una base sólida, transparente y extensible para la toma de decisiones informadas en entornos económicos reales.