

Universidad Pontificia de Comillas  
ICAI

## PROYECTO FINAL

Economía y Empresa

María González Gómez y Lydia Ruiz Martínez

# PREDICCIÓN DE LA TASA DE INFLACIÓN



Curso 2025-2026

## Resumen

Este informe presenta el diseño y la evaluación de una plataforma reproducible para predecir la inflación en España a partir de series históricas del Instituto Nacional de Estadística (INE). Para ello, se implementa un *pipeline* end-to-end que automatiza la descarga de datos, su depuración y enriquecimiento, el entrenamiento de modelos (ARIMA como línea base, y Random Forest/LSTM como alternativas), la generación de predicciones con intervalos de confianza y la elaboración de salidas visuales y un informe técnico. A nivel cuantitativo, el mejor desempeño se obtiene con *Random Forest* en el periodo de prueba analizado ( $MAE \approx 0,97$ ;  $RMSE \approx 1,95$ ;  $MAPE \approx 17,5\%$ ), con previsiones medias del entorno del 2,8% para el horizonte mensual considerado y bandas de incertidumbre medias cercanas a 0,6 puntos porcentuales. Este documento combina la justificación metodológica con una lectura económica prudente, resaltando límites y vías de mejora.

## Índice

|                                                          |   |
|----------------------------------------------------------|---|
| Índice                                                   | 2 |
| 1. Introducción                                          | 3 |
| 2. Contenidos del repositorio y cómo usarlo              | 3 |
| 3. Fuentes de datos y trazabilidad                       | 4 |
| 4. Qué se estudia, metodología y resultados con gráficos | 5 |
| 4.1. Objeto de estudio y preguntas . . . . .             | 5 |
| 4.2. Metodología . . . . .                               | 5 |
| 4.3. Resultados empíricos . . . . .                      | 6 |
| 5. Limitaciones conocidas y mejoras futuras              | 7 |
| 6. Conclusión                                            | 9 |

## 1. Introducción

La inflación es un fenómeno macroeconómico que incide directamente en el poder adquisitivo de los hogares, la competitividad de las empresas, la sostenibilidad de las finanzas públicas y la orientación de la política monetaria. La capacidad de anticipar su trayectoria, incluso a horizontes cortos (3–12 meses), tiene valor operativo para equipos de análisis económico, planificación presupuestaria y gestión de riesgo. En este trabajo abordamos la predicción de la tasa de inflación en España a partir de series oficiales del INE, con un enfoque que busca simultáneamente:

1. **Rigor en el dato:** trazabilidad completa desde la fuente (INE, servicio WS-Tempus) y controles de calidad.
2. **Disciplina de modelización:** una línea base *time-series* (ARIMA) y alternativas no lineales (Random Forest y LSTM) para capturar patrones potencialmente no lineales y dependencias complejas.
3. **Lectura económica:** interpretar resultados en clave macro (tendencia, estacionalidad, shocks transitorios) evitando sobreajuste y teniendo presente la incertidumbre estimada.

El proyecto pone especial énfasis en que el flujo sea **reproducible, auditable y utilizable** por profesionales de economía con mínima fricción técnica. Por ello, se ha diseñado una estructura de repositorio clara, configuración declarativa y una ejecución sencilla del *pipeline*. El resultado se entrega con **gráficos, tablas de métricas** y un **PDF técnico** con las conclusiones principales.

## 2. Contenidos del repositorio y cómo usarlo

El repositorio se organiza para favorecer la replicabilidad y la separación de responsabilidades:

- **config/:** ficheros de configuración (`config.yaml`) con las fechas de extracción, rutas, nivel de *logging* y, cuando aplica, los identificadores de las series del INE.
- **data/raw/** y **data/processed/:** datos descargados y datos procesados, respectivamente. La limpieza estandariza fechas, trata ausentes y outliers y deriva *features* (rezagos, ventanas móviles, etc.).
- **models/:** artefactos de modelos (`arima_model.pkl`, `random_forest_model.pkl`, `lstm_model.pkl`) con manifiesto de entrenamiento.
- **reports/:** salidas para usuarios (`predictions.csv/json`, visualizaciones PNG, `pipeline_execution_state.json` e informe PDF).

- `src/`: componentes del *pipeline*: extracción (`ine_extractor.py`), limpieza (`data_cleaner.py`), *feature engineering* (`feature_engineering.py`), entrenamiento (`model_trainer.py`), predicción (`predictor.py`) y generación de informes (`report_generator.py`). El archivo `main.py` orquesta de extremo a extremo.

**Ejecución mínima.** Con Python 3.10–3.12 y las dependencias de `requirements.txt`, basta con:

```
python src/main.py
```

Este comando ejecuta: descarga → limpieza → features → entrenamiento → predicción → reportes. Los registros se guardan en `logs/inflation_prediction.log`.

**Configuración esencial.** En `config/config.yaml` se definen:

- `data.start_date` y `data.end_date`;
- endpoints WSTempus del INE para IPC general, desagregaciones por grupos e IPCA (armonizado);
- `prediction.horizon_months` (meses a predecir; por defecto 12);
- rutas de `paths` y parámetros de `logging`.

## 3. Fuentes de datos y trazabilidad

Se emplean **series oficiales del Instituto Nacional de Estadística (INE)** obtenidas mediante el servicio **WSTempus**. Las series clave son:

1. *IPC general* (% interanual), que actúa como objetivo del modelo.
2. *IPC por grupos* (alimentación, energía, etc.), útiles como *features* explicativas para capturar composiciones y *base effects*.
3. *IPCA* (armonizado), que aporta comparabilidad europea y, en ocasiones, señal adicional.

**Trazabilidad.** El *pipeline* registra:

- fecha y hora de extracción;
- URL y *ID* de cada serie;
- número de observaciones descargadas y rango temporal;
- versiones de librerías y parámetros de modelización;

- métricas de evaluación y huellas de los artefactos (\*.pkl).

Esta información queda en `pipeline_execution.state.json` y en los logs. La limpieza documenta imputaciones y recortes de *outliers* cuando proceden. El objetivo es que un tercero pueda reproducir los resultados y auditar decisiones de transformación.

## 4. Qué se estudia, metodología y resultados con gráficos

### 4.1. Objeto de estudio y preguntas

El análisis busca responder, a un horizonte mensual (hasta 12 meses), a:

1. ¿En qué rango se moverá la inflación interanual en España bajo condiciones actuales?
2. ¿Qué patrón de tendencia y estacionalidad presentan los datos históricos?
3. ¿Qué aproximación (lineal o no lineal) ofrece mejor compromiso entre sesgo, varianza y robustez?

### 4.2. Metodología

**(1) Análisis exploratorio.** Se estudia la trayectoria histórica y la distribución de la tasa interanual, así como la descomposición clásica (tendencia, estacionalidad y residuo). Para economía aplicada, esto ayuda a distinguir *shocks* transitorios (p.ej., energía) de movimientos más persistentes.




Figura 1: Evolución histórica, tendencia/volatilidad y distribución de predicciones

(2) **Construcción de variables.** Además del objetivo (IPC interanual), se generan:

- *lags* del objetivo y de grupos del IPC (capturan persistencia);
- medias móviles y ventanas de volatilidad (suavizan y miden ruido);
- marcadores estacionales (mes del año) cuando procede;
- transformaciones *winsorized* para atenuar extremos.

(3) **Modelos.**

- **ARIMA (línea base).** Modelo clásico para series estacionarias tras diferenciación. Ventaja: interpretabilidad y parsimonia. Limitación: flexibilidad ante no linealidades y cambios de régimen.
- **Random Forest (RF).** Ensamble de árboles que capta interacciones y no linealidades. Adecuado cuando abundan *features* y hay estacionalidades suaves.
- **LSTM (opcional).** Red recurrente que puede modelar dependencias de largo alcance. Requiere más datos y *tuning*; sensible a la estandarización y al *early stopping*.

(4) **Evaluación.** Se usan MAE, RMSE y MAPE en un *holdout* temporal. La selección prioriza error absoluto (facilidad de interpretación en puntos porcentuales) y estabilidad. Se presentan también intervalos de confianza para las trayectorias previstas, útiles para comunicación de riesgo.

### 4.3. Resultados empíricos

**Comparativa de modelos.** En el ejercicio documentado, RF ofrece el mejor rendimiento agregado (MAE  $\approx 0,969$ ; RMSE  $\approx 1,950$ ; MAPE  $\approx 17,5\%$ ), seguido de LSTM (RMSE  $\approx 1,991$ ) y ARIMA (MAE  $\approx 2,496$ ; RMSE  $\approx 3,591$ ; MAPE  $\approx 61,4\%$ ). La lectura económica es que, con una estacionalidad relativamente suave y la presencia de *shocks* no lineales (picos 2022–2023), un ensamble no paramétrico maneja mejor las asimetrías y cambios de pendiente que un ARIMA puro.

**Descomposición y estacionalidad.** La descomposición estacional sugiere: (i) una tendencia con subidas acusadas 2022–2023 y posterior normalización hacia el rango 2–3,5%; (ii) un componente estacional pequeño pero estable, y (iii) residuos sin explosión de varianza. Esto avala que RF funcione bien (no necesita supuestos de homocedasticidad estricta y maneja *features* estacionales explícitas).




Figura 2: Comparación de rendimiento (MAE, RMSE, MAPE)

**Trayectoria prevista e incertidumbre.** Para el horizonte mensual examinado, la media de las predicciones ronda el 2,8 % (mediana  $\approx 2,84$  %; desviación estándar  $\approx 0,66$  pp), con extremos aproximados de 1,38 % y 3,64 %. El ancho medio de los intervalos de confianza del 95 % se sitúa cerca de 0,6 pp, estrechándose en tramos con mayor señal (*momentum*) y abriéndose en giros. En términos económicos, el escenario central describe una normalización compatible con transmisión gradual de shocks energéticos y efectos de base decrecientes, en un contexto de política monetaria restrictiva que ancla expectativas.

## Lectura macroeconómica sintética.

- **Tendencia:** tras el pico extraordinario 2022–2023, la senda proyectada converge a la franja 2–3,5 %, coherente con desvanecimiento de shocks de oferta y reanclaje de expectativas.
- **Estacionalidad:** patrones mensuales de baja amplitud, con pequeños repuntes esperables en determinados meses por componentes administrados o estacionales de demanda.
- **Riesgos:** sensibilidad a shocks energéticos (petróleo, gas), a la volatilidad de alimentos no elaborados y a posibles sorpresas de salarios/productividad que afecten a la subyacente.

## 5. Limitaciones conocidas y mejoras futuras

**Datos y cobertura.** Aunque la serie del IPC es robusta, la capacidad predictiva mensual depende de la calidad y puntualidad de componentes volátiles (energía, alimentos). El uso exclusivo de información del propio IPC limita la anticipación ante shocks exógenos. *Mejora:* incorporar *drivers* de alta frecuencia (Brent, tipo de cambio, indicadores de costes logísticos, PMIs, expectativas de inflación) y medidas de inflación subyacente.






Figura 3: Descomposición de la serie: original, tendencia, estacionalidad y residuo

**Especificación y estabilidad.** ARIMA ofrece una línea base interpretable pero sensible a cambios de régimen; RF y LSTM aumentan flexibilidad a costa de opacidad (en LSTM, además, riesgo de sobreajuste si los datos no son abundantes). *Mejora:* validación *rolling origin*, *time series cross-validation* y *ensembles* ponderados por desempeño.

**Incertidumbre y comunicación.** Las bandas reflejan incertidumbre condicional del modelo, no la *total*. Pueden infravalorar eventos de cola (política fiscal, shocks geopolíticos). *Mejora:* calibración empírica de cobertura, simulaciones *bootstrap*, escenarios alternativos (alto/bajo) y análisis de sensibilidad.

**Explicabilidad.** La interpretación económica se ve enriquecida si se explican contribuciones marginales de *features*. *Mejora:* *feature importance* en RF, SHAP para cuantificar el efecto de rezagos, estacionalidad y grupos del IPC; *partial dependence plots*.




Figura 4: Histórico y predicciones con intervalo de confianza

**Operativa y reproducibilidad.** Aunque el *pipeline* es reproducible, aún se puede reforzar la gobernanza: fijar versiones exactas de dependencias, registrar semillas (*seeds*) y añadir pruebas automatizadas de humo (*smoke tests*) y validaciones semánticas (sumas y medias consistentes). *Mejora*: manifiesto de modelos, control de versiones de datos (*data versioning*) y seguimiento de métricas por *run*.

## 6. Conclusión

En este proyecto se ha construido y documentado una solución end-to-end para la predicción de la inflación en España que cumple con los tres criterios exigidos en el enunciado docente: limpieza rigurosa del dato, construcción disciplinada del modelo y una interpretación económica clara de los resultados. La aportación principal es un *pipeline* automatizado, trazable y reproducible que, a partir de series oficiales del INE, genera predicciones mensuales con intervalos de confianza, gráficos interpretables y un informe técnico listo para su consumo por equipos de economía. Empíricamente, la alternativa no paramétrica *Random Forest* domina al ARIMA de referencia y a la especificación LSTM en el horizonte y *split* considerados, con errores medios razonables (MAE cercano a 1 pp; RMSE en el entorno de 2 pp) y bandas de incertidumbre de aproximadamente 0,6 puntos porcentuales. La senda proyectada sitúa la inflación en un rango compatible con la normalización posterior al ciclo de shocks 2022–2023, lo que sugiere una trayectoria central cercana al 2,8 % en el periodo evaluado, con riesgos inclinados hacia movimientos de materias primas y ciertos componentes volátiles del índice.

Desde una óptica económica, el mensaje clave es de prudente moderación: la




Figura 5: Evolución de la incertidumbre y bandas de confianza

descomposición muestra una estacionalidad acotada y una tendencia que converge, pero la experiencia reciente recuerda que la inflación es sensible a shocks de oferta, cambios en costes energéticos y reajustes de expectativas. Por ello, además de proyectar una mediana plausible, el informe enfatiza la importancia de comunicar la incertidumbre y de complementar el modelo con señales adelantadas (energía, tipo de cambio, encuestas empresariales, subyacente). Como líneas de trabajo, proponemos: (i) validación *rolling* y evaluación por ventana para acreditar estabilidad temporal; (ii) *ensembles* RF+LSTM ponderados por desempeño para reducir picos de error; (iii) explicabilidad mediante SHAP para reforzar la narrativa macro y la trazabilidad analítica; y (iv) escenarios alternativos que cuantifiquen el impacto de shocks razonables. Con todo ello, la plataforma proporciona una base sólida, transparente y extensible para la toma de decisiones informadas en entornos económicos reales.